

Comparative Analysis of Transfer Learning and Neuroevolution for Weed Image Classification Using the DeepWeeds Dataset

Kristopher Vela Domínguez
Ingeniería en Inteligencia Artificial
Universidad de Xalapa
Xalapa, Veracruz, México

Resumen—La clasificación automática de especies de maleza constituye una herramienta fundamental para el desarrollo de sistemas de agricultura de precisión, permitiendo reducir el uso indiscriminado de herbicidas y mejorar la eficiencia en la gestión de cultivos. En este trabajo se presenta una comparación experimental entre dos enfoques de aprendizaje profundo para clasificación de imágenes: una arquitectura basada en Transfer Learning mediante ResNet-50 y una arquitectura convolucional compacta inspirada en el enfoque de neuroevolución propuesto por DeepGA. Para la evaluación experimental se empleó el conjunto de datos DeepWeeds, compuesto por imágenes RGB de nueve clases correspondientes a distintas especies de maleza y una categoría negativa. Ambos modelos fueron entrenados bajo condiciones experimentales equivalentes con el objetivo de comparar su capacidad de clasificación, complejidad computacional y desempeño general utilizando métricas como Accuracy, Precision, Recall y F1-score.

Index Terms—Deep Learning, Transfer Learning, ResNet-50, DeepGA, Convolutional Neural Networks, DeepWeeds, Image Classification, Precision Agriculture.

I. INTRODUCCIÓN

Durante la última década, el aprendizaje profundo ha transformado significativamente el campo de la visión por computadora, permitiendo desarrollar sistemas capaces de reconocer objetos, segmentar imágenes y realizar tareas complejas de clasificación con un nivel de precisión superior al obtenido mediante técnicas tradicionales de procesamiento digital de imágenes. En particular, las Redes Neuronales Convolucionales (CNN) han demostrado una elevada capacidad para aprender automáticamente representaciones jerárquicas de los datos, eliminando la necesidad de diseñar manualmente descriptores visuales.

Dentro del ámbito agrícola, uno de los problemas más importantes corresponde a la identificación automática de malezas presentes en los cultivos. La detección temprana de especies invasoras permite optimizar la aplicación de herbicidas, disminuir costos de producción y reducir el impacto ambiental derivado del uso excesivo de productos químicos. Debido a la gran variabilidad existente en iluminación, perspectiva, condiciones climáticas y similitud

visual entre especies, este problema representa un desafío importante para los sistemas de clasificación automática.

Entre las estrategias actuales para abordar este tipo de problemas destacan dos enfoques diferentes. El primero corresponde al Transfer Learning, donde arquitecturas previamente entrenadas sobre grandes bases de datos, como ImageNet, son adaptadas para resolver nuevos problemas mediante el reentrenamiento de sus últimas capas. El segundo consiste en la neuroevolución, donde algoritmos evolutivos generan automáticamente la arquitectura de la red neuronal buscando maximizar el desempeño obtenido durante el entrenamiento.

En este trabajo se realiza una comparación experimental entre ambos enfoques utilizando el conjunto de datos DeepWeeds. Se implementa una arquitectura ResNet-50 basada en Transfer Learning y una arquitectura convolucional inspirada en el paradigma de neuroevolución utilizado por DeepGA., evaluando su desempeño bajo las mismas condiciones experimentales. Finalmente, se comparan indicadores relacionados con la precisión de clasificación, capacidad de generalización, tiempo de entrenamiento, complejidad computacional y eficiencia de ambas soluciones.

II. MATERIALES Y MÉTODOS

II-A. Conjunto de datos

Para el desarrollo del proyecto se seleccionó el conjunto de datos público DeepWeeds, diseñado específicamente para la identificación automática de malezas presentes en cultivos agrícolas mediante imágenes RGB adquiridas en condiciones reales de campo.

El conjunto de datos contiene un total de 17 509 imágenes distribuidas en nueve categorías, correspondientes a ocho especies de maleza de importancia agrícola y una clase denominada *Negative*, utilizada para representar escenas donde no aparece ninguna de las especies objetivo.

La elección de DeepWeeds se realizó considerando diversos factores. En primer lugar, representa un problema de aplicación real dentro de la agricultura de precisión. Además, constituye un conjunto de datos considerablemente menos utilizado que otros empleados frecuentemente en la literatura, como CIFAR-10, CIFAR-100 o Fashion-MNIST, permitiendo desarrollar una comparación experimental sobre un escenario con mayor complejidad visual y menor grado de saturación académica.

Las imágenes presentan variaciones importantes de iluminación, orientación, escala, textura y fondo, lo que incrementa la dificultad del proceso de clasificación y exige una adecuada capacidad de generalización por parte de los modelos implementados.

II-B. Exploración del conjunto de datos

Como primera etapa del experimento se realizó un análisis exploratorio del conjunto de datos con el propósito de conocer su distribución, verificar la cantidad de imágenes disponibles por categoría e identificar posibles desbalances entre clases.

La Figura 1 presenta la distribución de las nueve categorías presentes en DeepWeeds. Puede observarse que la clase *Negative* concentra aproximadamente la mitad de las imágenes disponibles, mientras que las ocho especies restantes presentan cantidades relativamente similares, cercanas a las mil imágenes por categoría.

Aunque el conjunto de datos presenta cierto desbalance, éste corresponde al diseño original del dataset y representa adecuadamente la frecuencia con la que aparecen escenas sin presencia de maleza durante la adquisición de imágenes en campo.




Figura 1. Distribución de imágenes por clase en el conjunto DeepWeeds.

II-C. Visualización de ejemplos

Con el objetivo de comprender la variabilidad presente en el conjunto de datos, se seleccionaron imágenes representativas de las diferentes categorías.

La Figura 2 muestra algunos ejemplos utilizados durante el entrenamiento. Se observa una alta variabilidad en condiciones de iluminación, perspectiva, tamaño de los objetos y complejidad del fondo, factores que incrementan la dificultad del problema de clasificación.



Figura 2. Ejemplos representativos del conjunto DeepWeeds.

II-D. Preprocesamiento

Antes del entrenamiento, todas las imágenes fueron redimensionadas para adaptarse al tamaño de entrada requerido por las arquitecturas implementadas. En el caso de ResNet-50 se utilizaron imágenes de 224×224 píxeles, respetando el tamaño esperado por el modelo preentrenado sobre ImageNet.

Con el propósito de mejorar la capacidad de generalización del modelo durante el entrenamiento se aplicaron técnicas de aumento de datos (*Data Augmentation*), incluyendo rotaciones aleatorias y reflejos horizontales.

Posteriormente, las imágenes fueron convertidas a tensores y normalizadas utilizando los parámetros estadísticos correspondientes al conjunto de datos ImageNet, permitiendo aprovechar adecuadamente los pesos previamente aprendidos durante el proceso de Transfer Learning.

II-E. Particiones del conjunto de datos

DeepWeeds proporciona divisiones oficiales para entrenamiento, validación y prueba, garantizando que los experimentos sean completamente reproducibles.

Con el propósito de reducir el tiempo de entrenamiento debido a las limitaciones de hardware disponibles, se empleó un subconjunto representativo del conjunto original, conservando la distribución general de las clases y manteniendo la separación entre entrenamiento, validación y prueba.

Esta estrategia permitió realizar múltiples experimentos bajo condiciones controladas sin comprometer la validez de la comparación entre ambas arquitecturas.

III. METODOLOGÍA

III-A. Arquitectura basada en Transfer Learning

Como primer enfoque se implementó una arquitectura ResNet-50 utilizando aprendizaje por transferencia. El modelo fue inicializado con los pesos preentrenados sobre ImageNet, aprovechando el conocimiento previamente adquirido durante el entrenamiento sobre más de un millón de imágenes.

Durante la adaptación al problema de clasificación de DeepWeeds se congelaron todas las capas convolucionales de la red, permitiendo únicamente el entrenamiento de la capa clasificadora final. Dicha capa fue reemplazada por una nueva capa totalmente conectada de nueve neuronas, correspondientes a las nueve clases presentes en el conjunto de datos.

Esta estrategia permitió reducir considerablemente el número de parámetros entrenables y el tiempo requerido para la optimización, manteniendo las características visuales aprendidas durante el preentrenamiento.

III-B. Arquitectura tipo DeepGA

Como segundo enfoque se implementó una red neuronal convolucional compacta inspirada en el paradigma de neuroevolución empleado por DeepGA.

La arquitectura utilizada estuvo conformada por tres bloques convolucionales consecutivos, cada uno seguido por funciones de activación ReLU y operaciones de MaxPooling. Finalmente se incorporó una capa de *Adaptive Average Pooling* y un clasificador totalmente conectado con regularización mediante Dropout.

La red contiene únicamente 94 409 parámetros entrenables, lo que representa una reducción significativa respecto a ResNet-50 y permite disminuir el consumo de memoria durante el entrenamiento.

III-C. Configuración experimental

Ambos modelos fueron entrenados bajo condiciones experimentales equivalentes para garantizar una comparación objetiva.

Las imágenes fueron redimensionadas a una resolución de 224×224 píxeles para ResNet-50 y posteriormente normalizadas utilizando las estadísticas de ImageNet.

Durante el entrenamiento se empleó el optimizador Adam con una tasa de aprendizaje de 1×10^{-3} , un tamaño de lote de 16 imágenes y una función de pérdida basada en entropía cruzada (*Cross Entropy Loss*). Cada arquitectura fue entrenada durante cinco épocas utilizando el mismo

subconjunto del conjunto de datos

Todos los experimentos fueron ejecutados localmente sobre un equipo equipado con un procesador AMD Ryzen 5 3450U y 16 GB de memoria RAM, sin aceleración mediante GPU.

Cuadro I
CONFIGURACIÓN EXPERIMENTAL UTILIZADA

Parámetro	Valor
Learning Rate	1×10^{-3}
Batch Size	16
Épocas	5
Optimizador	Adam
Función de pérdida	Cross Entropy Loss
Resolución	224×224
Hardware	Ryzen 5 3450U
RAM	16 GB
GPU	No utilizada

IV. RESULTADOS EXPERIMENTALES

IV-A. Resultados obtenidos con ResNet-50

Después del congelamiento de las capas convolucionales, únicamente permanecieron entrenables 18 441 parámetros correspondientes a la capa clasificadora final. Y luego de cinco épocas de entrenamiento, ResNet-50 alcanzó una precisión del 50.00 % sobre el conjunto de prueba.

La Figura 3 muestra la matriz de confusión correspondiente al modelo, mientras que la Figura 4 presenta la evolución de la pérdida y la precisión durante el entrenamiento.




Figura 3. Matriz de confusión obtenida con ResNet-50.




Figura 4. Curvas de entrenamiento de ResNet-50.




Figura 6. Evolución del accuracy durante el entrenamiento de la CNN tipo DeepGA.

IV-B. Resultados obtenidos con la CNN tipo DeepGA

Debido a las limitaciones computacionales del entorno de experimentación, no se ejecutó un proceso evolutivo completo de múltiples generaciones. En su lugar, se implementó una arquitectura compacta representativa del tipo de soluciones que DeepGA busca obtener mediante neuroevolución, permitiendo realizar una comparación directa bajo las mismas condiciones experimentales. La arquitectura inspirada en DeepGA alcanzó una precisión del 47.29 % sobre el conjunto de prueba.

Aunque el desempeño fue ligeramente inferior al obtenido por ResNet-50, la diferencia fue reducida considerando que la arquitectura posee un número considerablemente menor de parámetros entrenables.

Las Figuras 5, 6 y 7 muestran la matriz de confusión y las curvas de entrenamiento correspondientes.




Figura 5. Matriz de confusión obtenida con la CNN tipo DeepGA.




Figura 7. Evolución de la función de pérdida durante el entrenamiento de la CNN tipo DeepGA.

Cuadro II
COMPARACIÓN ENTRE LAS ARQUITECTURAS EVALUADAS

Indicador	ResNet-50	CNN tipo DeepGA
Accuracy validación (%)	47.14	43.00
Accuracy prueba (%)	50.00	47.29
Parámetros	23 526 473	94 409
Tiempo de entrenamiento (min)	17.29	18.27
Épocas	5	5
Batch Size	16	16
Optimizador	Adam	Adam

V. DISCUSIÓN

Los resultados muestran que ResNet-50 obtuvo el mejor desempeño en términos de precisión de clasificación, alcanzando un 50.00 % de accuracy sobre el conjunto de prueba. Este comportamiento era esperado debido al uso de aprendizaje por transferencia y al conocimiento previamente adquirido sobre ImageNet.

Sin embargo, la arquitectura tipo DeepGA obtuvo un accuracy del 47.29 %, quedando únicamente 2.71 puntos porcentuales por debajo de ResNet-50. Este resultado adquiere especial relevancia al considerar que la CNN compacta utiliza únicamente 94 409 parámetros, frente a los más de 23 millones de parámetros de ResNet-50.

Desde el punto de vista computacional, la arquitectura tipo DeepGA representa una alternativa significativamente más eficiente en memoria y complejidad, manteniendo un

rendimiento competitivo para el problema analizado.

Los resultados obtenidos permiten concluir que el aprendizaje por transferencia continúa ofreciendo el mejor desempeño cuando existen modelos preentrenados disponibles. No obstante, las arquitecturas compactas inspiradas en técnicas de neuroevolución constituyen una alternativa atractiva para escenarios con recursos computacionales limitados, donde el tamaño del modelo y el consumo de memoria son factores determinantes.

Debe considerarse que ambos modelos fueron entrenados durante únicamente cinco épocas y utilizando un subconjunto representativo del conjunto DeepWeeds debido a las restricciones de hardware disponibles. En consecuencia, los valores absolutos de desempeño podrían incrementarse significativamente al entrenar durante un mayor número de épocas o utilizando el conjunto completo de imágenes.

VI. CONCLUSIONES

El objetivo principal del proyecto fue comparar experimentalmente una arquitectura basada en aprendizaje por transferencia con una arquitectura convolucional compacta inspirada en técnicas de neuroevolución para el problema de clasificación de imágenes de maleza utilizando DeepWeeds.

Los resultados obtenidos muestran que ResNet-50 alcanzó el mejor desempeño general, obteniendo un accuracy del 50.00 %, mientras que la CNN tipo DeepGA obtuvo un accuracy del 47.29 %. A pesar de esta diferencia, la segunda arquitectura requirió únicamente una fracción de los parámetros utilizados por ResNet-50, evidenciando una mayor eficiencia computacional.

Durante el desarrollo del proyecto se reforzaron conocimientos relacionados con aprendizaje por transferencia, preparación de conjuntos de datos, entrenamiento de redes neuronales convolucionales, evaluación mediante métricas de clasificación y análisis comparativo de arquitecturas profundas.

Como trabajo futuro se propone ejecutar un algoritmo DeepGA completamente funcional, incrementar el número de generaciones evolutivas y entrenar ambos modelos utilizando la totalidad del conjunto DeepWeeds sobre hardware con aceleración GPU.

REFERENCIAS

- [1] N. Olsen et al., "DeepWeeds: A Multiclass Weed Species Image Dataset for Deep Learning," *Scientific Reports*, vol. 9, 2019.
- [2] K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition," *CVPR*, 2016.
- [3] J. Deng et al., "ImageNet: A Large-Scale Hierarchical Image Database," *CVPR*, 2009.
- [4] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," *NeurIPS*, 2019.